BASES DE DATA + AI

O que é a Arquitetura Medalhão?

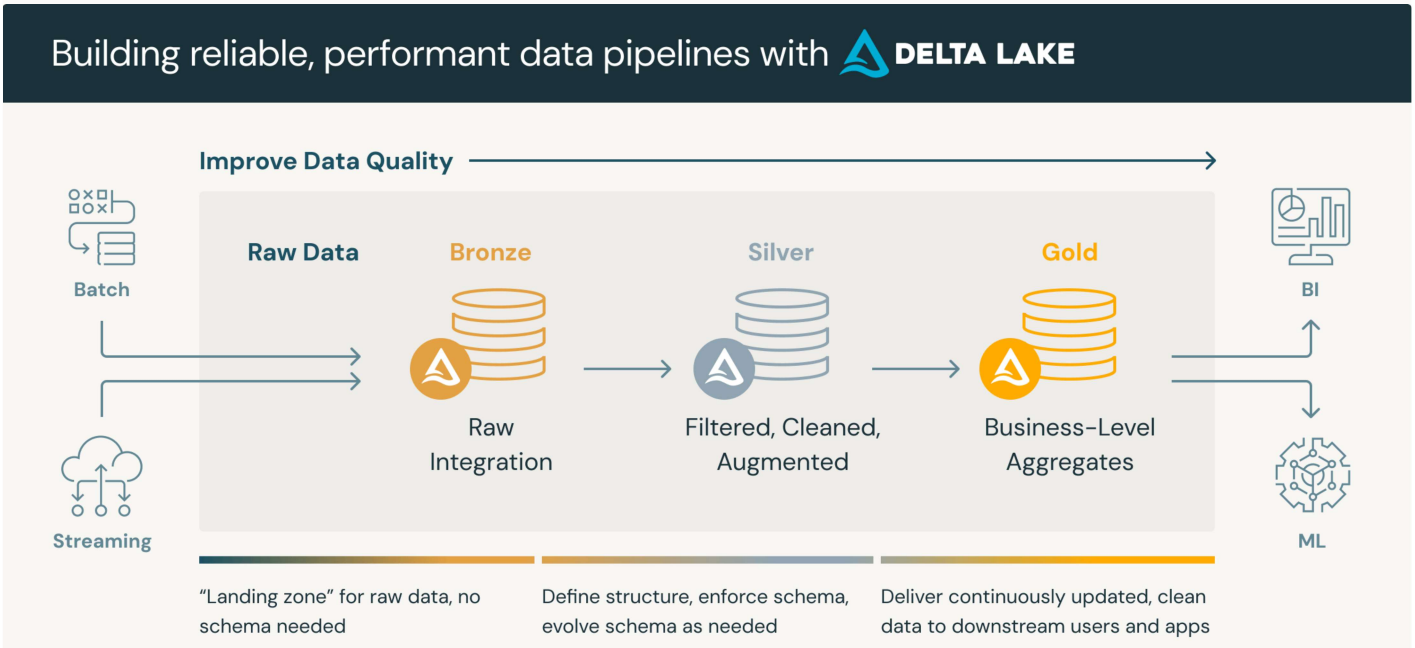
O padrão de projeto Lakehouse organiza os dados em camadas de bronze (bruto), prata (limpo) e ouro (agregado) para um refinamento progressivo da qualidade dos dados.

por Equipe da Databricks

RESUMO

O que é uma arquitetura medallion?

A **arquitetura medallion** se refere ao design de dados usado para organizar logicamente os dados do lakehouse, que visa melhorar de forma incremental e progressiva a estrutura e a qualidade dos dados à medida que fluem pelas três camadas da arquitetura (tabelas Bronze ⇒ Prata ⇒ Ouro). As arquiteturas medallion também são conhecidas como arquitetura “multi-hop”.



Criação de pipelines de dados com arquitetura medallion

O Databricks oferece ferramentas como Delta Live Tables (DLT), que possibilitam a criação instantânea de pipelines de dados com tabelas Bronze, Prata e Ouro, usando apenas algumas linhas de código. Além disso, com tabelas de transmissão e visualizações materializadas, é possível desenvolver pipelines DLT de transmissão baseados no Apache Spark™ Structured Streaming, que são atualizados de forma incremental. Para mais detalhes, consulte a documentação da Databricks sobre a combinação dessas funcionalidades em um único pipeline.

Camada bronze (dados brutos)

A **camada Bronze** armazena todos os dados de sistemas de origem externa. As estruturas da tabela desta camada correspondem às estruturas da tabela "como estão" no sistema de origem, juntamente com metadados de colunas adicionais, como data de carregamento, ID do processo etc. Essa camada fornece captura rápida de dados alterados, arquivamento histórico de fonte (armazenamento a frio), linhagem de dados, auditabilidade e reprocessamento conforme necessário, sem recarregar os dados do sistema de origem.

Camada Prata (dados limpos e adaptados)

A **camada Prata** do lakehouse combina, faz merge, adapta e limpa (moderadamente) os dados na camada Bronze para fornecer uma "visão corporativa" de todas as principais entidades de negócios, conceitos e transações (por exemplo, tabelas mestre de clientes, lojas, transações desduplicadas e referência cruzada).

A camada Prata traz dados de fontes diferentes para uma visão corporativa, permitindo análises de autoatendimento, como relatórios ad hoc, análises avançadas e ML. Os dados da camada Prata são a fonte de projetos e análises para analistas, engenheiros de dados e data scientists para ajudar a resolver desafios de negócios em empresas e projetos de dados departamentais na camada Ouro.

No lakehouse, a engenharia de dados segue, geralmente, a abordagem ELT em vez de ETL. Isso significa que, ao carregar os dados na camada Prata, aplica-se apenas um nível moderado de transformação e limpeza. O foco está na ingestão rápida e na entrega eficiente de dados ao data lake, deixando regras de negócio mais complexas e transformações específicas para o carregamento na camada Ouro. Em termos de modelagem, a camada Prata adota um modelo de dados próximo à Terceira Forma Normal e oferece suporte a abordagens como Data Vault.

EBOOK

Principais conclusões sobre sistemas multiagentes, casos de uso de IA, avaliações e muito mais

Leia agora

Camada Ouro (tabelas de nível empresarial selecionadas)

Os dados na **camada Ouro** do lakehouse são normalmente organizados em bancos de dados consumíveis "somente para projetos". A camada Ouro é boa para relatórios e usa um modelo de dados com menos junção, mais desnormalizado e otimizado para leitura. É a camada final para transformações de dados, regras de qualidade de dados e apresentação em projetos como análise de clientes, análise de qualidade do produto, análise de estoque, segmentação de clientes, recomendação de produtos, análise de marcação/vendas. Muitos modelos de dados baseados em esquemas em estrela estilo Kimball, ou data marts estilo Inmon, se encaixam nessa camada Ouro de lakehouse.

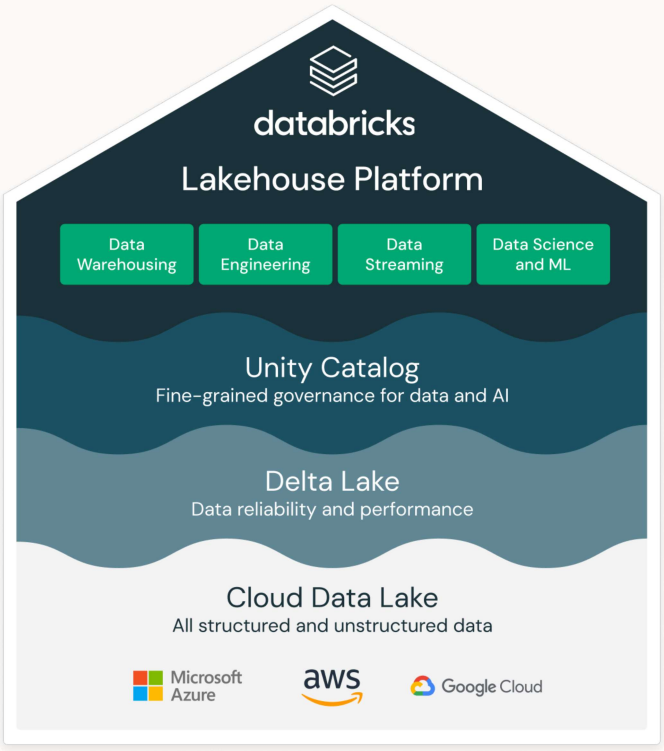
Dessa forma, os dados são selecionados à medida que se movem pelas diferentes camadas do lakehouse. Em alguns casos, data marts e EDWs de pilhas de tecnologia RDBMS tradicionais são trazidos para o lakehouse para permitir a primeira análise avançada "pan-EDW" e ML na empresa. É algo que não é possível com pilhas tradicionais ou porque é muito caro (por exemplo, conectando dados de IoT/fabricação com dados de vendas/marketing para realizar análise de defeitos e genômica de assistência médica, construindo um data lake de assistência médica vinculando os mercados de dados clínicos EMR/HL7 e dados de crédito financeiro para analisar e melhorar o atendimento).

Benefícios de uma arquitetura lakehouse

- Modelo de dados simples
- Fácil de entender e implementar
- Habilita ETL incremental
- Pode recriar suas tabelas a partir de dados brutos a qualquer momento
- Transações ACID, dados históricos

Uma rápida introdução sobre lakehouses

Lakehouse é uma arquitetura de plataforma de dados que combina os melhores aspectos de data lakes e data warehouses. Um lakehouse moderno oferece alta escalabilidade e desempenho, armazenando dados brutos e preparados para viabilizar consumo ágil, insights avançados e uma tomada de decisão mais eficiente nos negócios. Essa abordagem elimina silos de dados e permite acesso seguro e contínuo a uma única plataforma para usuários autenticados em toda a empresa.



Arquitetura medallion e malha de dados

A arquitetura medallion é compatível com o conceito de **malha de dados**. As tabelas Bronze e Prata podem ser unidas de maneira "um para muitos", de modo que os dados de uma tabela upstream possam ser usados para gerar várias tabelas downstream.

[Experimente a Databricks gratuitamente hoje mesmo]

Recursos adicionais

- O que é data lakehouse?
- Plataforma Data Lakehouse da Databricks

- Como ETL incremental simplifica a vida com os data lakes - Blog Databricks
- Simplifique sua arquitetura medallion com o recurso CDF de Delta Lake